

Deteccion automatica de enfermedades en hojas de papas mediante redes convolucionales

Hermann Tobias José, Kieffer Lucas
Trabajo Final de Inteligencia Computacional
Ingenieria Informatica
UNL Facultad de Ingeniería y Ciencias Hídricas

Resumen

En este informe se pretende clasificar imagenes de papas con enfermedades *early blight* y *late blight* mediante el uso de redes. convolucionales

Index Terms

CNN, enfermedad, cultivo, papa, InceptionV3, augmentacion, convolucion

I. INTRODUCCIÓN

La alimentación es una de las necesidades básicas de la vida humana. La demanda de alimentos está aumentando debido al aumento exponencial de la población mundial [1]. Para superar una demanda tan masiva de alimentos, los profesionales agrícolas sugirieron el uso de diferentes insecticidas y pesticidas para aumentar el rendimiento de los cultivos. El uso de estos insecticidas y pesticidas aumenta el rendimiento de las plantas, pero usarlos en grandes cantidades puede degradar la calidad del suelo, lo que hace que los cultivos sean más propensos a diferentes enfermedades. Sin embargo, detectar enfermedades en un gran campo de cultivos a simple vista es una tarea desafiante. Por tanto, para simplificar este proceso, existe la necesidad de un sistema de detección automática de enfermedades de las plantas, como se explica en una de las citas [2] donde el principal problema en la producción de alimentos son las enfermedades en plantas, afectando al maiz que es el principal producto de la india que juega un papel crucial en la alimentación, y donde se intenta abordar el problema con un sistema de detección automático.

Nuestro enfoque principal se centrará en las papas[3], una fuente esencial de nutrientes para poblaciones en todo el mundo. Estos cultivos, a pesar de su importancia, enfrentan amenazas persistentes, entre las cuales destacan dos enfermedades prominentes: el Early Blight, causado por el hongo *Alternaria solani*, que se manifiesta en manchas oscuras en las hojas inferiores de la papa, y el Late Blight, causado por el oomycete *Phytophthora infestans*, caracterizado por manchas irregulares de color verde oscuro a negro en las hojas [4].



Fig. 1: Dataset

La capacidad de identificar y diagnosticar tempranamente la presencia de estas enfermedades en las plantas no solo facilita una respuesta rápida y específica, sino que también contribuye a la optimización de recursos agrícolas, minimizando el uso de pesticidas y reduciendo los impactos ambientales asociados[5]. Es por esta razón, que decidimos aplicar técnicas de inteligencia computacional en la detección automática de enfermedades por imágenes como una herramienta que nos ayudará en la identificación anticipada de este problema[6]. En este trabajo, nos enfocaremos en la identificación de estas dos enfermedades mediante el empleo de redes convolucionales para el análisis de imágenes. Además, como se ha demostrado en Arnaud[4], el uso de modelos convolucionales preentrenados trae consigo resultados favorables

II. PROPUESTA DE SOLUCIÓN

Detallaremos el desarrollo e implementación de nuestro propio sistema, así como la utilización de la arquitectura Inception (transfer learning), una red neuronal convolucional profunda desarrollada por Google en 2015. Se utiliza como base datos un repositorio de acceso abierto de enfermedades de los cultivos de Bangladesh [7].

A. Red Convolucional

Las redes convolucionales surgieron en 1998 propuestas por Lecun, Y[8] para el reconocimiento de dígitos. Están compuestas por las siguientes partes:

A.1. Capa de convolución: La operación de convolución implica deslizar un filtro o kernel sobre la entrada y realizar un producto punto a lo largo del área de contacto. Este proceso se realiza para cada posición posible de la ventana del filtro en la entrada. Esto permite a la red aprender características locales, como bordes en una imagen, y también reduce la cantidad de parámetros que la red necesita aprender




Fig. 2: Capa Convolución

A.2. Capa de pooling: Capas de agrupación (pooling): Estas capas reducen la dimensionalidad de los datos, agrupando pequeñas regiones (por ejemplo, bloques 2x2) y manteniendo solo el valor máximo (max pooling) o el promedio (average pooling). Esto proporciona una cierta invarianza a pequeñas traslaciones y reduce la cantidad de parámetros.




Fig. 3: Capa Pooling

A.3. Capa completamente conectada: Después de varias capas de convolución y agrupación, las CNN terminan con una o más capas completamente conectadas. Estas capas pueden realizar la clasificación final, por ejemplo, utilizando la función softmax para proporcionar probabilidades de salida para cada clase.

B. Modelo Propio

Para nuestro modelo se utilizó como base el modelo propuesto por Akther J[3]. Se modificó teniendo en cuenta las características de la base de datos. El resumen del modelo es el siguiente:

Layer (type)	Output Shape
Conv2d-1	[128, 299, 299]
MaxPool2d-1	[128, 150, 150]
Conv2d-2	[64, 151, 151]
MaxPool2d-2	[64, 76, 76]
Linear-1	[3]
Softmax	[3]

TABLA I: Arquitectura Propia

C. Modelo InceptionV3

InceptionV3[9] es una arquitectura de red neuronal convolucional entrenada en 2015 para el conjunto de datos ImageNet. Utiliza múltiples tamaños de filtros en paralelo y luego concatenar las salidas.

El mismo recibe como entrada una imagen RGB de tamaño 299 de alto por 299 de ancho. Tiene como salida un vector columna de tamaño 1000. Nosotros vamos a reemplazar las últimas 2 capas finales, por una capa fully connected de 1000 a 3 y tomaremos como salida el clasificador el argmax de estas 3 salidas. Se entrenan solamente los pesos de la capa reemplazada, los otros pesos del modelo entrenados a partir del dataset ImageNet estarán congelados.




Fig. 4: InceptionV3

D. Dataset

Nuestro Dataset se compone de tres tipos de clases diferentes, el Early Blight con 1000 representaciones, Late Blight con 1000 representaciones y Healthy con 152 representaciones. Todas las imágenes tienen un tamaño de 256x256 y un fondo sencillo para detallar o hacer mas foco en la hoja respectivamente.[7]

D.1. Partición de los datos: Del total de los datos, se separaron un 20 % para test y un 20 % para validación. Luego, a partir del 60 % restante para train se realizó la aumentación de datos.

E. Aumentacion de datos

Otro factor importante es el desafío de tener representaciones de datos desiguales en las clase, generando resultados sesgados a favor de las clases con más representación[10], por lo tanto, requerimos métodos para equilibrar sus tasas de reconocimiento. Podemos optar por el método de remuestreo, sobremuestreo o aumentación de datos, siendo este último el aplicado.

La aumentación de datos por rotación consiste en generar nuevas muestras de datos al aplicar rotaciones a las imágenes existentes, de esta manera se espera mejorar la capacidad del modelo para generalizar[11] y reconocer patrones independientemente de la orientación de las imágenes. En nuestro caso se toman las imágenes de Healthy y se realizan 6 rotaciones aleatorias a cada imagen para igualar la cantidad de muestras en el conjunto train de cada clase, es decir, llevamos de 96 a aproximadamente 600 imágenes de Healthy.



Fig. 5: Aumentacion de datos

III. RESULTADOS

A. Entrenamiento

Se entrenó el modelo con un máximo de 50 épocas y una paciencia de 5 épocas tomando como parámetro el accuracy balanceado. Un tamaño de batch de 16 patrones. Como criterio de error se utilizó *CrossEntropy*. Se utilizó el optimizador *Adam*, ya que funciona mejor respecto al SGD[4]




Fig. 6: Loss Train, Loss Val

En el gráfico se puede apreciar como la red comienza a *sobreentrenarse* luego de la quinta época. Tanto el accuracy de train como el accuracy de test son balanceados $AB = \frac{AE+AH+AL}{3}$. Donde AE es el accuracy de Early, AH es el accuracy de Healthy y AL es el accuracy de Late.

B. Resultados obtenidos

Modelo	Balanced Accuracy	Early	Healthy	Late	Epocas
Propio	92	92.5	86.6	98.5	7
Propio con Aumentación	88	95	76.6	94	12
InceptionV3	100	100	100	100	20
InceptionV3 con Aumentación	95	92	100	94.5	5

IV. CONCLUSIÓN

Los resultados obtenidos no fueron como los esperados en un inicio, observamos una disminución en la precisión (accuracy) en comparación con el conjunto de datos original sin aumentar. Aunque la aumentación de datos la utilizamos para mejorar la capacidad del modelo para generalizar y reconocer patrones en diversas situaciones, en este caso específico, parece haber tenido un impacto negativo en la capacidad de predecir nuestro modelo. Esta reducción en la precisión puede deberse a varios motivos, como la características específica de las imágenes o la posibilidad de que la rotación sola no sea la mejor forma para realizar un aumentacion de datos.

Además se puede apreciar que el modelo InceptionV3 funciona mejor que nuestro modelo, sin embargo, el costo de hacer el *fine-tuning* del modelo fue mucho mayor. También utilizar InceptionV3 requiere mayor memoria y capacidad de procesamiento para realizar la inferencia. La inferencia con InceptionV3 sobre el conjunto de test dura 9.8 segundos, mientras que el modelo propio demora 4.6 segundos

A pesar de todo esto, los resultados en términos del problema son buenos, con una precisión que supera el 90 % (alcanzando el 100 % en el caso de InceptionV3) lo que le aporta al sistema una confiabilidad notable en la identificación de las enfermedades.

REFERENCIAS

- [1] N. M. Malana y H. Malano, "Benchmarking productive efficiency of selected wheat areas in pakistan and india using data envelopment analysis," *Irrigation and Drainage*, vol. 55, 2006.
- [2] E. Akanksha, N. Sharma, y K. Gulati, "Opnn: Optimized probabilistic neural network based automatic detection of maize plant disease detection," en *2021 6th International Conference on Inventive Computation Technologies (ICICT)*, pp. 1322–1328, 2021.
- [3] J. Akther, A.-A. Nayan, y M. Harun-Or-Roshid, "Potato leaves blight disease recognition and categorization using deep learning," *Eng. J.*, vol. 27, no. 9, pp. 27–38, Sep 2023.
- [4] S. Arnaud, N. Rehema, S. Aoki, y M. Kananu, "Comparison of deep learning architectures for late blight and early blight disease detection on potatoes," *Open Journal of Applied Sciences*, vol. 12, pp. 723–743, 2022.
- [5] D. Pandey y V. Singh, "Automatic rice plant disease recognition and identification using convolutional neural network," *Journal of Critical Reviews*, vol. 7, no. 15, pp. 6079–6086, 2020.

- [6] M. M. Islam, M. A. Talukder, M. R. A. Sarker, M. A. Uddin, A. Akhter, S. Sharmin, M. S. A. Mamun, y S. K. Debnath, "A deep learning model for cotton disease prediction using fine-tuning with smart web application in agriculture," *Intelligent Systems with Applications*, vol. 20, p. 200278, 2023. [Online]. Disponible: <https://www.sciencedirect.com/science/article/pii/S2667305323001035>
- [7] N. A. Moin, "New bangladeshi crop disease dataset," [Accessed: 11-Nov-2023], 2023, recuperado de <https://www.kaggle.com/datasets/nafishamoin/new-bangladeshi-crop-disease/>.
- [8] Y. Lecun, L. Bottou, Y. Bengio, y P. Haffner, "Gradient-based learning applied to document recognition," *Proceedings of the IEEE*, vol. 86, no. 11, pp. 2278–2324, 1998.
- [9] C. Szegedy, V. Vanhoucke, S. Ioffe, J. Shlens, y Z. Wojna, "Rethinking the inception architecture for computer vision," 2015.
- [10] M. Tan, D. Langenkämper, y T. W. Nattkemper, "The impact of data augmentations on deep learning-based marine object classification in benthic image transects," *Sensors*, vol. 22, no. 14, 2022. [Online]. Disponible: <https://www.mdpi.com/1424-8220/22/14/5383>
- [11] F. Quiroga, F. Ronchetti, L. C. Lanzarini, y A. Rosete, "Revisiting data augmentation for rotational invariance in convolutional neural networks," 2021.